Правительство Российской федерации
Федеральное государственное автономное учреждение
высшего профессионального образования
«Национальный исследовательский университет
«Высшая школа экономики»

Факультет Компьютерных наук
Магистерская программа «Науки о Данных»
Департамент больших данных и информационного поиска

КУРСОВАЯ РАБОТА МАГИСТРА

Реализация и сравнение алгоритмов планирования DAG в распределенных системах

Выполнил студент группы АИД
Александров Роман Игоревич

Научный руководитель:
кандидат технических наук, доцент
Сухорослов Олег Викторович

Москва 2017

Оглавление

Введение

В работе представлена задача планирования вычисления DAG в распределенных вычислительных системах. Согласно статье [1], задача поиска оптимального расписания является NP-полной. Поэтому для наиболее качественного и при этом быстрого решения данной задачи было придумано много различных приближенных методов. Часть из них будут затронуты в данной работе — классические алгоритмы решения этой задачи, а также применение генетического алгоритма. Кроме того будет проведено сравнение данных подходов. В работе представлена постановка задачи. В главе 1 описаны классические эвристические алгоритмы планирования. В главе 2 представлена адаптация генетического алгоритма к данной задаче. В главе 3 приведены результаты проведенных экспериментов и сравнение алгоритмов затронутых в данной работе.

Постановка задачи

Введем две модели - модель вычислительной среды и модель вычислительного приложения, которая как раз описывается с помощью DAG (Directed acyclic graph). Это две важные части задачи планирования. Также нужно отметить, что предполагается наличие некоторой управляющей системы которая будет распределять задачи на вычислительные ресурсы и запускать их в нужное время. Будем считать что всевозможные накладные расходы работ этой части системы малы и ими можно пренебречь.

Вычислительная среда состоит из ресурсов R_i $(1 \leq i \leq M)$ с различной производительностью. Между каждой парой ресурсов есть сетевое соединение с заданной пропускной способностью. При этом эффектами взаимодействия потоков данных обычно пренебрегают. Возможен учет дополнительных факторов и характеристик: объем доступной памяти, количество ядер процессора или вероятность отказа ресурса. В дальнейшем будем предполагать что вероятность отказа за время работы отдельного приложения крайне мала и может игнорироваться.

Композитные приложения (КП) удобно описывать на языке потоков работ (workflow). Поток работ обычно представляется в виде направленного ациклического графа (DAG). Вершины графа T_a $(1 \leq a \leq N)$ отражают выполнение отдельной задачи в КП, а ребра C_{ab} задают зависимость или связь между задачами. Кроме того на ребрах определен объем данных c_{ab} который нужно передать от задачи T_a к задаче T_b только после завершения задачи T_a и до нача-

ла выполнения задачи T_b. Если присутствует связь C_{ab} значит задачу T_a называют (непосредственным) родителем задачи T_b , а задачу T_b дочерней T_a. Дочерние задачи не могут быть начаты пока не завершились все их родители. Для всех рассматриваемых далее методов планирования необходима возможность оценить время выполнения задач на любом ресурсе вычислительной среды. Обозначим эту оценку как $EET(T_a, R_i)$ (EET = Estimated Execution Time) и будем считать её известной. Аналогично времени выполнения EET, обозначим время передачи данных от задачи T_a к T_b как $ECOMT(C_{ab}, R_i, R_j)$ ($ECOMT$ = Estimated Communication Time). Есть различные подходы к оценке $ECOMT$, но чаще всего используют простую линейную модель

$$ECOMT(c_{ab}, R_i, R_j) = t_{con} + \frac{c_{ab}}{L_{ij}}$$

,где t_{con} латентность соединения, L_{ij} - пропускная способность сети между ресурсами R_i, R_j.

Отметим, что при практической реализации планирования вопрос вычисления EET и оценки $ECOMT_{ab}$ является сложной независимой задачей.

В рамках введенной модели мы можем описать время завершения каждой задачи и всего приложения в целом. Пусть задача T_a выполняется на ресурсе R_j, а ее родительские задачи T_b - на ресурсах R_{j_b}. Тогда:

$$ECT(T_a) = EET(T_a, R_i) + \max_{b \in \text{родительские задачи}} (ECOMT(c_{ab}, R_i, R_{j_b}) + ECT(T_b, R_{j_b}))$$

Оценка времени завершения последней задачи в композитном приложении $ECT_{\max} = \max_a(ECT(T_a)$ определяет время выполнения всего композитного приложения.

В данной работе будут рассмотрены алгоритмы планирования с наилучшим качеством, то есть алгоритмы которые минимизируют время выполнения всего приложения.

Описание стандартных алгоритмов планирования композитных приложений в распределенной вычислительной среде

В данной главе рассматриваются классические методы приоритетного планирования. Данные алгоритмы стараются учитывать полную структуру композитного приложения. Их основной идеей является то, что лучшие ресурсы должны быть выделены под задачи, которые оказывают наибольшее влияние на общее время выполнение композитного приложения. Классическим примером таких алгоритмов является HEFT (Heterogeneous Earliest Finish Time, [3]). Также можно выделить алгоритм DLS (Dynamic Levels Scheduler, [2]), который также является удачным развитием данного подхода.

Алгоритм HEFT

Алгоритм HEFT относительно простой и при этом экспериментально эффективный. Его часто берут за эталонный при сравнении по эффективности и скорости составления расписания с новыми алгоритмами. Работу данного алгоритма можно разбить на два этапа — упорядочивание задач и размещение их на ресурсы.

На первом шаге производится ранжирование задач по следующему признаку:

$$rank(T_a) = \overline{\text{EET}}(T_a) = \max_{T_b \in \text{дочерние задачи } T_a} (\overline{\text{ECOMT}}(c_{ab}) + rank(T_b))$$

Здесь $\overline{\text{EET}}(T_a)$ — средняя оценка времени выполнения задачи T_a по всем ресурсам, $\overline{\text{ECOMT}}(c_{ab})$ — среднее время передачи объема данных c_{ab} между всевозможными парами ресурсов.

Затем все задачи в приложении планируются в неубывающем порядке значения функции $rank(T_a)$. Нельзя не отметить важную особенность функции ранжирования — родительская задача всегда имеет более высокий приоритет чем ее дочерние задачи. Благодаря такому свойству на момент планирования каждой задачи известно, где будут выполнены все её родительские задачи. Критерием выбора ресурса выполнение является минимизация ECT. Таким образом, задачи с большим значением $rank$ получают более производительные ресурсы. Для повышения эффективности используется планирование со вставками. Такое планирование может ставить задачу в любой достаточный для выполнения промежуток свободного времени ресурса. Благодаря этому низкоприоритетная задача может выполниться на ресурсе до высокоприоритетной, пока высокоприоритетная задача ожидает выполнения родительских задач.

Итого, алгоритм $HEFT$ можно представить в следующем виде:

for all T_a **do**

$rank(T_a) \leftarrow \overline{\text{EET}}(T_a) = \max_{T_b \in \text{дочерние задачи } T_a} (\overline{\text{ECOMT}}(c_{ab}) + rank(T_b))$

$OrderedTasks \leftarrow$ задачи отсортированные по убыванию $rank_{T_a}$

for all $T \in OrderedTasks$ **do**

$R \leftarrow arg\min_{R_i} ECT(T, R_i)$

Запланировать выполнение задачи T на R

Алгоритм DLS

Алгоритм DLS тоже основывается на идеи рангов. Однако, в алгоритме DLS ранг считается для пары — ресурс, задача. В оригинальной статье этот ранг называются Dynamic Levels, отсюда и название алгоритма. На первом шаге алгоритма для каждой задачи считается SL (SL = Static Level):

$$SL(T_a) = \overline{\text{EET}}(T_a) + \max_{T_b \in \text{дочерние задачи } T_a}(SL(T_b))$$

Уже на основе посчитанного статического ранга высчитывается Dynamic Level для каждой пары ресурс/задача:

$$DL(T_a, R_i, Timetable) = SL(T_a) + D(T_a, R_i) - EEST(T_a, R_i, Timetable)$$

Здесь SL — Static Level. $D(T_a, R_i)$ — разница между временем выполнения задачи T_a на ресурсе R_i и на усредненном ресурсе. $EEST(T_a, R_i, Timetable)$ (EEST = Earliest Execution Start Time) наименьшее время, когда задача T_a, может начать выполняться на ресурсе R_i. Чтобы посчитать $EEST(T_a, R_i, Timetable)$ нужно знать расписание на конкретном ресурсе R_i и знать время конца выполнения всех родительских задач, отсюда и зависимость от $Timetable$.

Отличие данного алгоритма от HEFT в том, что ранги высчитываются по мере планирования задач на ресурсы. Об этом и говорит название которое выбрали для ранга — Dynamic Level. Изначально DL посчитан для всех задач у которых нет зависимостей так как они уже готовы к выполнению. Далее на каждом шагу выбирается пара задача/ресурс которая имеет максимальный DL. Данная задача планируется к выполнению на этом ресурсе на минимально возможное время, то есть здесь

также используем алгоритм вставок в расписание. Потом DL вычисляется для всех задач у которых стало известно время конца выполнения всех родительских задач.

Весь алгоритм выглядит так:

for all T_a **do**

$SL(T_a) \leftarrow \overline{\mathrm{EET}}(T_a) + \max\limits_{T_b \in \text{дочерние задачи } T_a}(SL(T_b))$

$ReadyToSchedule \leftarrow$ задачи готовые к выполнению

for all $T_a \in ReadyToSchedule$ **do**

for all R_i **do**

$DL(T_a, R_i) \leftarrow SL(T_a) + D(T_a, R_i) - EEST(T_a, R_i)$

while $ReadyToSchedule \neq \varnothing$ **do**

$R, T \leftarrow arg \max\limits_{T_a \in ReadyToSchedule, R_i}(DL(T_a, R_i))$

Запланировать выполнение задачи T на R

$ReadyToSchedule \leftarrow ReadyToSchedule - \{R\}$

$ReadyChilds \leftarrow$ дети задачи R готовые к выполнению

$ReadyToSchedule \leftarrow ReadyToSchedule \cup ReadyChilds$

for all $T_a \in ReadyChilds$ **do**

for all R_i **do**

$DL(T_a, R_i) \leftarrow SL(T_a) + D(T_a, R_i) - EEST(T_a, R_i)$

Алгоритм генетического поиска для решения задачи планирования композитных приложений в распределенной вычислительной среде

Генетический алгоритм поиска является универсальной концепцией для приближенного решения трудновычислимых задач. Его приложение к задаче планирования описано более подробно здесь [4]. Здесь же будет краткое описание работы алгоритма.

Общий вид генетического алгоритма одинаков для всех приложений:

1. Инициализация начального поколения

while Критерий остановки не выполнен **do**

2. Кроссовер

3. Мутация

4. Оценка поколения

5. Выбор в новое поколение хромосом

Основную роль в генетическом алгоритме играет элемент поколения — хромосома. В рамках задачи планирования хромосома выглядит как пара строк. Одна строка, будем называть её mat задает соответствие между задачей и ресурсом. Вторая строка — ss задает последовательность задач в которой они будут запланированы. Важно что ss является некоторой топологической сортировкой ацикличного графа композитного приложения.

В начальное поколение генетического алгоритма нужно добавлять совсем случайные хромосомы и хромосомы которые соответствуют реше-

ниям построенным другими различными эвристиками, например с помощью DLS или HEFT. Тогда генетический алгоритм может улучшить какое-то из решений с помощью случайных процессов которые происходят с хромосомами.

Кроссовер является одной из наиболее важных частей алгоритма. Он помогает обмениваться информацией между двумя хромосомами — создавать новые хромосомы отличные от родительских. Кроссовер между двумя *mat* строками просто режет их в одинаковых частях и меняет отрезанные части. Кроссовер между двумя *ss* строками также режет их в одинаковых местах и потом в отрезанной части строки задачи переставляются в порядке, задаваемым строкой с которой происходит кроссовер.

Мутация позволяет создавать хромосомы с совсем новым решением. Процесс мутации для *mat* строки очень простой — выбирается случайная задача и ей в соответствие задается случайный ресурс. Мутация же *ss* строки происходит чуть сложнее. Выбирается случайная задача и переносится в случайное место такое, чтобы новая строка также являлась топологической сортировкой.

Пример DAG и возможных строк *ss* и *mat* для данной DAG и вычислительной сети с тремя ресурсами.

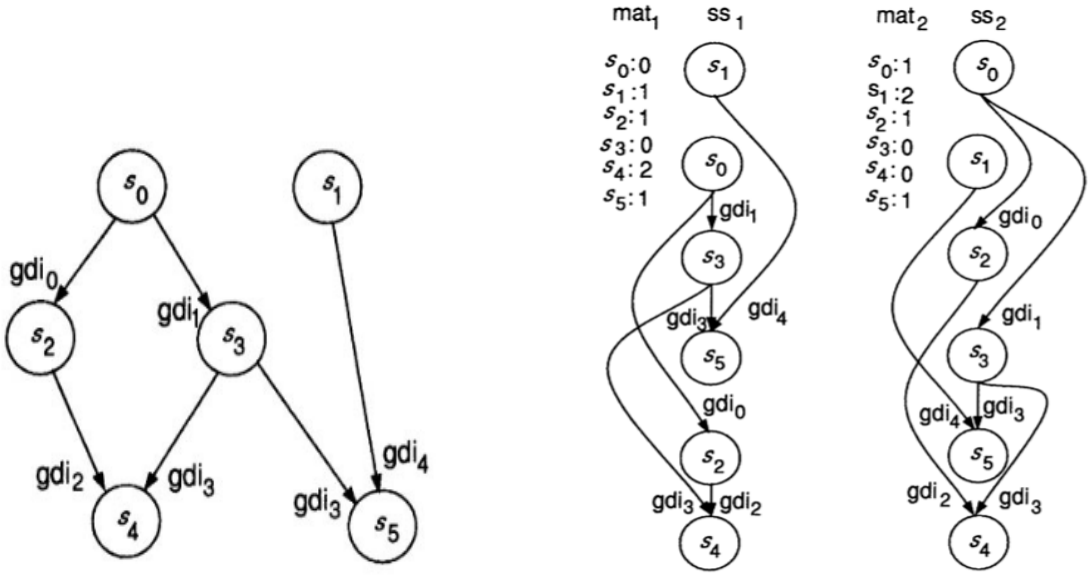

Оценка хромосомы осуществляется с помощью симуляции или того расписания которое было построено (оно дает приблизительное время

выполнения композитного приложения так как в составлении расписания не учитывается общее пользование сети). После того как все элементы поколения получили оценку, они сортируются на основе этой оценки и потом в зависимости от места в порядке сортировки им присуждается вероятность с которой они будут выбраны. Выбор производится с повторением, то есть некоторые хромосомы могут дублироваться, однако это будут скорее всего хромосомы с хорошим расписанием. Для i-го элемента будет следующая вероятность:

$$P_i = R^{N-i-1}(1-R)/(1-R^N)$$

N — размер популяции, R - параметр алгоритма.

Помимо R у генетического алгоритма есть и другие параметры. Одни из них является размер популяции N. Также есть параметры связанные с мутацией и кроссовером. Процесс кроссовера происходит так — популяция разбивается на $N/2$ пар и для каждой пары с вероятность $P_{crossover}$ происходит кроссовер. Аналогично существует и вероятность мутации $P_{mutation}$ для каждого элемента популяции. Кроме того, в данной адаптации есть параметр — количество популяции, что есть просто количество итераций цикла. Удачная настройка этих параметров позволяет получать более качественные результаты. Однако, такую настройку можно произвести только сделав несколько экспериментальных запусков алгоритма.

Эксперименты

В рамках этой работы были реализованы алгоритмы DLS и генетический алгоритм. Реализации алгоритмов добавлены в открытый сборник алгоритмов, который находится на сервисе github [5]. Данный репозиторий содержит алгоритмы, тестовые приложения и различные конфигурации вычислительных систем и самое важное там находится удобная обертка над программой моделирования вычисления приложения в распределенной системе.

Ниже представлены результаты работы алгоритмов на разных конфигурациях вычислительной сети и разных композитных приложениях. Все результаты нормированы по значению работы алгоритма HEFT. Видно что DLS несильно отличается от него. GA в свою очередь улучшает результат работы стандартных методов с помощью мутаций и кроссовера. Параметры использованные для получения таких результатов следующие: $N = 50$, $Iterations = 300$, $P_{mutation} = 1.0$, $P_{crossover} = 0.8$.

Nets	HEFT	DLS	GA	Nets	HEFT	DLS	GA
CyberShake				Inspiral			
5	1.0000	1.0008	0.9892	5	1.0000	0.9994	0.9740
10	1.0000	1.0014	0.9753	10	1.0000	1.0029	0.9599
20	1.0000	0.9993	0.9833	20	1.0000	1.0107	0.9538
Epigenomics				Montage			
5	1.0000	1.0028	0.9680	5	1.0000	0.9989	0.9905
10	1.0000	1.0090	0.9500	10	1.0000	0.9927	0.9855
20	1.0000	1.0010	0.9552	20	1.0000	0.9759	0.9697

Заключение

Генетический алгоритм достаточно сложен в настройке, однако результаты которые можно с помощью него достигнуть могут быть намного лучше простых эвристических подходов. Эксперименты показали что генетический алгоритм заметно улучшает стандартные решения полученные для начального поколения. Алгоритмы DLS и HEFT показывают примерно одинаковое качество, однако сильно выигрывают по времени составления расписания у генетического алгоритма.

Литература

1. R.L. Graham, E.L. Lawler, J.K. Lenstra и A.H.G.Rinnooy Kan. «Optimization and Approximation in Deterministic Sequencing and Scheduling: a Survey». В: Discrete Optimization 17 IIProceedings of the Advanced Research Institute on Discrete Optimization and Systems Applications of the Systems Science Panel of NATO and of the Discrete Optimization Symposium co-sponsored by IBM Canada and SIAM Banff, Aha. and Vancouver. Под ред. E.L. Johnson P.L. Hammer и B.H. Korte. Т. 5. Annals of Discrete Mathematics. Elsevier, 1979, с. 287—326. doi: http://dx.doi.org/10.1016/S0167-5060(08)70356-X. url: http://www.sciencedirect.com/science/article/pii/S016750600870356X.

2. G. C. Sih и E. A. Lee. «Dynamic-level scheduling for heterogeneous processor networks». В: Parallel and Distributed Processing, 1990. Proceedings of the Second IEEE Symposium on. Дек. 1990, с. 42—49. doi: 10.1109/SPDP.1990.143505

3. H. Topcuoglu, S. Hariri и Min-You Wu. «Task scheduling algorithms for heterogeneous processors». В: Heterogeneous Computing Workshop, 1999. (HCW '99) Proceedings. Eighth. 1999, с. 3—14. doi: 10.1109/HCW.1999.765092

4. Lee Wang, Howard Jay Siegel, Vwani P. Roychowdhury и Anthony A. Maciejewski. «Task Matching and Scheduling in Heterogeneous Computing Environments Using a Genetic- Algorithm-Based Approach». В: J. Parallel Distrib. Comput. 47.1 (нояб. 1997), с. 8—22. issn: 0743-7315. url: http://dx.doi.org/10.1006/jpdc.1997.1392

5. [HTTP] https://github.com/alexmnazarenko/pysimgrid